RAPPORT D'ANALYSE TECHNIQUE : NLP & MULTIMODAL

Évaluation des Coûts de Sinistres Workers' Compensation (Cellules 7 à 14)

Auteurs : Marius Occhiminuti · Gaëtan Amiens | **Cours :** Data Mining & Machine Learning (DMML) – Synthèse W1–W10

1. Objectifs & Périmètre Expérimental (Cellules 7 à 14)

L'objectif de cette phase d'expérimentation est d'exploiter la variable textuelle non structurée `ClaimDescription` (récit de l'accident du travail) pour améliorer la prédiction du coût final des sinistres (`UltimateIncurredClaimCost`).

- **Évolution NLP :** Évaluer la progression depuis les modèles fréquentiels de sac de mots (TF-IDF) jusqu'aux représentations denses contextuelles obtenues par un modèle Transformer pré-entraîné (`distilbert-base-uncased`).
- **Fusion Multimodale :** Combiner les caractéristiques tabulaires (démographie, données financières, délais de déclaration) avec les représentations textuelles au sein de pipelines étanches sous Scikit-learn et LightGBM.
- **Analyse du Compromis Précision–Coût :** Mesurer la précision de prédiction (MAE, RMSE, R^2) face au coût computationnel et aux contraintes d'exécution sur processeur (CPU) et carte graphique (GPU).

2. Exploration NLP par Sac de Mots & Inspection TF-IDF (Cellule 7)

Une première vectorisation `TfidfVectorizer(max_features=300, stop_words='english', ngram_range=(1, 2))` a été ajustée sur le jeu d'entraînement (80 000 lignes).

2.1 Fréquence Globale vs. Importance Décisionnelle LightGBM

L'analyse comparative entre les mots-clés les plus fréquents (score TF-IDF moyen) et les termes retenus par LightGBM dans ses arbres de décision (`feature_importances_`) révèle une dissociation majeure :

Indicateur	Analyse & Mots-Clés Référencés
Fréquence TF-IDF	**Top Termes :** `right`, `left`, `strain`, `lower`, `lifting`, `finger`, `hand`, `knee`. *Analyse métier :* Domination de termes anatomiques génériques et de latéralité (*right*, *left*) qui apportent peu de signal financier.
Importance LightGBM	**Top Termes Décisionnels :** `head` (74), `soft tissue` (66), `eye` (54), `fractured` (32), `crushed` (18). *Analyse métier :* Concentration du pouvoir prédictif sur les marqueurs de gravité clinique fortement corrélés à des arrêts longs et des coûts majeurs.

3. Optimisation du Pipeline TF-IDF + LightGBM (Cellule 8)

Pour dépasser la baseline initiale, le pipeline a été optimisé par deux leviers :

1. **Élargissement du Vocabulaire :** Passage de 300 à 1 000 variables TF-IDF incluant les trigrammes (`ngram_range=(1, 3)`) pour capturer des expressions médicales complètes (ex: *"repetitive stress injury"*, *"lower back pain"*).
2. **Réglage d'Hyperparamètres LightGBM :** `n_estimators=300`, `learning_rate=0.03`, `num_leaves=63`, `subsample=0.8`, `colsample_bytree=0.8`.

- **Résultats de l'Optimisation :** MAE = $\$\mathbf{10\,547,70}$ (Nouveau record vs $\$10\,551,61$), RMSE = $\$\mathbf{48\,785,79}$, $R^2 = \mathbf{0,0215}$ (progression de $+16,8\%$ par rapport au modèle initial $0,0184$). Temps d'entraînement : $37,12$ **secondes**.

4. Embeddings Contextuels Denses avec DistilBERT (Cellules 9 & 10)

Afin de capturer la sémantique profonde au-delà du sac de mots, nous avons extrait les représentations vectorielles denses du jeton `[CLS]` (768 dimensions) via `distilbert-base-uncased` (PyTorch).

- **Système de Cache sur Disque :** Sauvegarde sous format `.npy` (`distilbert_train_emb.npy`, `distilbert_test_emb.npy`) pour éviter la recomputation à chaque exécution du notebook.
- **Fusion Multimodale Brute :** Concaténation des 15 variables tabulaires et des 768 dimensions denses (783 variables).
- **Résultats Brut DistilBERT :** MAE = $\$10\,567,78$, $R^2 = 0,0169$, Temps d'entraînement = $205,48$ **secondes** ($5,5\times$ plus lent).
- **Diagnostic Technique :** Les arbres de décision (LightGBM) éprouvent des difficultés à effectuer des coupes d'axes efficaces dans un espace continu dense à 768 dimensions sans sélection de variables préalable ou fine-tuning métier.

5. Stratégies d'Optimisation Multimodale & Contraintes Matérielles (Cellules 11 à 13)

5.1 Stratégie A : Réduction de Dimension PCA (768d → 32d) + Fusion Hybride (Cellule 11)

Une analyse en composantes principales (`PCA(n_components=32)`) a été appliquée sur les embeddings DistilBERT, conservant $79,86\%$ **de la variance sémantique**.

- **Matrice Hybride (1 047 variables) :** Tabulaire (15d) + PCA-DistilBERT (32d) + TF-IDF (1 000d).
- **Résultats PCA :** MAE = $\$10\,549,93$, RMSE = $\$48\,817,48$, $R^2 = \mathbf{0,0203}$. Temps de calcul divisé par 4 ($56,53$**s**).
- **Bénéfice :** La PCA a supprimé la colinéarité et le bruit des représentations denses, permettant à LightGBM de retrouver un niveau de précision quasi-équivalent au record TF-IDF tout en intégrant l'information contextuelle de DistilBERT.

5.2 Stratégie B : Fine-Tuning End-to-End DistilBERT (Cellule 12) & Contrainte CPU/Timeout

Nous avons configuré une régression de séquence directe (`AutoModelForSequenceClassification`, `num_labels=1`) avec PyTorch et le `Trainer` HuggingFace pour adapter les poids du réseau à la prédiction du coût $\log(1+y)$.

- **Contrainte Computationnelle sur CPU :** Sur le jeu de données complet (80 000 paires texte–cible) exécuté sur processeur (CPU) sans accélération GPU dédiée sous Jupyter, l'entraînement complet a estimé une durée de **7 à 10+ heures**, conduisant à un *timeout* du kernel Python.
- **Analyse des Goulots d'Étranglement :** L'analyse des performances GPU (GeForce GTX 1060) sous Windows a mis en évidence un goulot d'étranglement côté CPU lors de la préparation des batchs textuels (*Data Loading*).

5.3 Stratégie C : Stacking Multimodal (Cellule 13)

L'architecture de Stacking prévoyait l'injection de la prédiction log issue du DistilBERT fine-tuné en tant que méta-feature dans LightGBM.

6. Tableau Comparatif Global des Modèles NLP & Multimodaux

Le tableau ci-dessous résume l'ensemble des configurations testées lors des cellules 7 à 14 sur le jeu de test de 20 000 sinistres :

Configuration / Stratégie	Dim. Texte	RMSE ($)	MAE ($)	R^2	Temps (s)
`dummy_mean_baseline`	0	50 442,06	11 189,54	−0,0460	2,98
Baseline TF-IDF (300d) + LightGBM	300d (sparse)	48 864,09	10 551,61	+0,0184	8,33
Optimisé TF-IDF (1000d) + LightGBM (Sec. 8)	**1000d (sparse)**	**48 785,79**	**10 547,70**	**+0,0215**	**37,12**
DistilBERT Brut (768d) + LightGBM (Sec. 10)	768d (dense)	48 901,37	10 567,78	+0,0169	205,48
Stratégie A : Hybrid PCA (32d) + LightGBM (Sec. 11)	**1032d (hybride)**	**48 817,48**	**10 549,93**	**+0,0203**	**56,53**
Stratégie B : Fine-Tuning DistilBERT (Sec. 12)	768d (fine-tuned)	–	– (CPU Timeout)	–	> 7h (CPU)

7. Synthèse Méthodologique & Prochaines Étapes pour le Rendu

- **Principe de Parcimonie (Rasoir d'Ockham) :** Le modèle **TF-IDF (1 000 n-grams) + LightGBM** offre le meilleur compromis opérationnel : il obtient la meilleure précision (MAE = $\$10\,547,70$), est $5,5\times$ plus rapide que DistilBERT brut, et offre une interprétabilité directe des mots-clés médicaux.
- **Performance de la PCA :** L'approche hybride **PCA (32d) + TF-IDF + LightGBM** démontre qu'une réduction de dimension efficace permet d'intégrer des embeddings denses de Transformers dans des modèles d'arbres sans dégradation de vitesse ou de précision.
- **Prochaines Étapes Validées :**
  1. **Triage des Gros Sinistres (Top 10% / Classification) :** Transformer la cible pour évaluer la capacité du modèle à classifier les sinistres extrêmes (> $\$12\,900$) via des métriques de précision et d'AUC.
  2. **Explicabilité Globale & Locale par Valeurs SHAP :** Générer les graphiques d'attribution de caractéristiques (*SHAP Summary Plot* et *Force Plot*) pour offrir une transparence complète aux gestionnaires d'assurance.